



Искусственный интеллект в науках о Земле

Михаил Криницкий

к.т.н.,
зав. Лабораторией машинного обучения в науках о Земле МФТИ
с.н.с. Институт океанологии РАН им. П.П. Ширшова



Задачи классификации

Михаил Криницкий


К.Т.Н.,
зав. Лабораторией машинного обучения в науках о Земле МФТИ
с.н.с. Институт океанологии РАН им. П.П. Ширшова

КЛАССИФИКАЦИЯ ЗАДАЧ МАШИННОГО ОБУЧЕНИЯ

Формулировка задачи (в терминах машинного обучения)

- «Обучение с учителем»
 - восстановление регрессии
 - классификация

ЧТО Я ХОЧУ? – метку класса
«красный или синий?»
(бинарная классификация)



ЗАДАЧА КЛАССИФИКАЦИИ

Простейший пример:

объекты описываются действительным признаком x

целевая переменная y – бинарная, классы: A , B ; по 1000 экземпляров каждого класса

пусть для класса $y = A$ значения $x \sim \mathcal{N}(\mu_A, \sigma_A)$, для класса $y = B$ значения $x \sim \mathcal{N}(\mu_B, \sigma_B)$

Базируясь на этих данных, каково должно быть
решение (значение y) при:

$$x = -10$$


$$x = -5$$

$$x = 2$$

$$x = 5$$

$$x = 10$$

$$x = 15$$




ЗАДАЧА КЛАССИФИКАЦИИ

Простейший пример: объекты описываются действительным признаком x
 целевая переменная y – бинарная, классы: A , B ; по 1000 экземпляров каждого класса
 пусть для класса $y = A$ значения $x \sim \mathcal{N}(\mu_A, \sigma_A)$, для класса $y = B$ значения $x \sim \mathcal{N}(\mu_B, \sigma_B)$

Подход №1: KNN (метод K ближайших соседей)

1. выбрать K ближайших соседей для нового объекта (! нужно определить меру близости !)
2. осреднить (можно с разными весами) целевую переменную по этим объектам («простое голосование», «majority vote» или «взвешенное голосование», «weighted vote»)
3. считать полученный результат значением целевой переменной на новом объекте



ЗАДАЧА КЛАССИФИКАЦИИ

Подход получше – оценить **вероятность** классов **A** и **B** для объекта, описываемого значением x .

$$P(Y = k | X = x)$$

ЗАДАЧА КЛАССИФИКАЦИИ

Подход получше – оценить **вероятность** классов A и B для объекта, описываемого значением x .

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

Кстати, если нужно принять решение относительно значения Y при определенном значении x_i , помним, что $P(x_i)$ – константа, которую можно не учитывать при сравнении $P(Y = A|X = x_i)$ и $P(Y = B|X = x_i)$

$$P(X) = \sum_{y_i} P(X|Y = y_i)P(Y = y_i)$$

формула полной вероятности

ЗАДАЧА КЛАССИФИКАЦИИ

Подход получше – оценить **вероятность** классов A и B для объекта, описываемого значением x .

$$P(Y|X) = \frac{P(X|Y) \ P(Y)}{P(X)}$$

Кстати, если нужно принять решение относительно значения Y при определенном значении x_0 , помни, что $P(x_0)$ – константа, которую можно не учитывать при сравнении $P(Y = A|X = x_0)$ и $P(Y = B|X = x_0)$

ЕСЛИ нам повезло и Мы ЗНАЕМ (или полагаем как допущение в процессе решения) распределения X для каждого из классов $P(X|Y = A)$, $P(X|Y = B)$ etc., - то можно получить **аналитическое решение!**

И это решение будет ЛУЧШИМ из всех возможных.

ЗАДАЧА КЛАССИФИКАЦИИ

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

ЕСЛИ нам повезло и мы знаем (или полагаем как допущение в процессе решения) распределения X для каждого из классов $P(X|Y = A)$, $P(X|Y = B)$ etc., - то можно получить **аналитическое решение!**

объекты описываются действительным признаком x

целевая переменная y – бинарная



пусть для класса $y = A$ значения $x \sim \mathcal{N}(\mu_A, \sigma_A)$, для класса $y = B$ значения $x \sim \mathcal{N}(\mu_B, \sigma_B)$

$$\mu_A = 5$$

$$\mu_B = -2$$

$$\sigma_A = 2$$

$$\sigma_B = 3$$



ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

ЕСЛИ нам повезло и мы знаем (или полагаем как допущение в процессе решения) распределения X для каждого из классов $P(X|Y = A)$, $P(X|Y = B)$ etc., - то можно получить **аналитическое решение!**

$$P(Y = B|X = x) = \frac{e^{-\frac{(x+2)^2}{2*9}} * \frac{1}{2}}{e^{-\frac{(x-5)^2}{2*4}} * \frac{1}{2} + e^{-\frac{(x+2)^2}{2*9}} * \frac{1}{2}}$$

«Байесовский классификатор»
(не путать с «naïve bayes»)

